

圖形理論期末專題報告

專題名稱：

用於社群假訊息傳播分析與推播限流模擬之
動態信任圖模型

摘要

社群媒體推薦系統通常會依據使用者關係、互動紀錄、內容興趣分數與 AI 預測結果進行推播。然而，若系統過度依賴流量與互動量，具有爭議性或情緒刺激性的內容可能因留言、點擊與分享較高而被大量曝光，進而造成假訊息快速擴散。本專題提出一套以圖論為基礎的動態信任圖模型，將使用者表示為節點，將訊息可能流動的方向表示為有向邊，並針對使用者對使用者之間的關係、互動與信任建立推播分數。為簡化實際社群平台複雜的 AI 推薦流程，本專題聚焦於可解釋的圖論模型，參考 X / Twitter Heavy Ranker 的加權排序概念，設計 RelationScore、InteractionScore 與 TrustScore，並以線性加權方式形成最終 Score 矩陣。其中，關係分數表示接收者是否追蹤發文者，互動分數表示接收者對發文者內容的互動程度，信任分數則表示發文者是否具有可信傳播紀錄。系統進一步設定信任限流門檻與推播門檻，當節點信任分數過低時，將限制其對外傳播能力；當邊的推播分數不足時，則將其排除於有效推播圖之外。

實作上，本專題使用 Python、NetworkX、NumPy、PySide6 與 Matplotlib 建立互動式 GUI 系統，並結合 BFS 模擬訊息擴散、Dijkstra 分析高風險傳播路徑、PageRank 評估節點影響力，以及強連通元件偵測潛在回聲室。結果顯示，加入信任機制後，高風險節點即使仍存在於圖中，也會因信任不足而失去對外推播能力，使系統能降低假訊息擴散風險，並更清楚呈現可信的社群傳播結構。

目錄

第一章、緒論.....	3
第二章、文獻探討.....	6
第三章、研究方法.....	8
第四章、結果與討論.....	16
第五章、結論與建議.....	19
第六章、參考文獻.....	20
附錄.....	20

第一章、緒論

一、研究動機

市面上的社群媒體平台在進行內容推薦時，通常不只依據使用者之間的追蹤、好友或互動關係，也會分析貼文對於特定使用者的興趣分數，例如使用者是否可能按讚、留言、分享、點擊、查看作者頁，或停留在該內容上較長時間。這些推薦機制多半會結合 AI 預測模型，依照使用者過去行為與內容特徵，推估某篇貼文是否值得出現在使用者的資訊流中。

然而，這種以流量與互動表現為核心的推播邏輯也可能造成問題。若一則貼文具有高度話題性、爭議性或情緒刺激性，即使內容未經查證，仍可能因為大量留言、轉發與點擊而被系統判斷為「高互動內容」。在 Facebook、Threads、X 等社群平台中，使用者所看到的內容不一定完全依照時間排序，而常受到推薦演算法影響；因此，若演算法過度重視互動，假訊息便可能因爭議性高而被快速推播至更多使用者。

為了解決這個問題，本專題設計一套「動態信任圖模型」。本專題並不嘗試完整重現大型社群平台複雜的 AI 推薦流程，而是將推薦問題簡化為圖論中的「使用者對使用者」推播關係。也就是說，本專題不直接分析貼文語意或每位使用者對每篇貼文的完整興趣預測，而是聚焦於三項與使用者關係有關的可量化特徵：關係、互動與信任。

其中，關係分數表示兩個節點之間是否存在追蹤關係，並用來估計接收者是否較容易看到或被推播發文者的內容；互動分數表示接收者對發文者內容的互動程度；信任分數則表示發文者是否經常傳播可信資訊或假訊息。本專題特別強調信任關係：若某帳號大量傳送被證實的假訊息，則其信任分數會下降；當信任分數低於門檻時，該帳號將被限流，甚至無法將訊息推播出去，但仍能保留在圖中接收其他節點傳來的訊息。

換言之，本專題希望建立一種「高互動不必然等於高推播」的圖論模型。即使某帳號與其他使用者關係良好、互動頻繁，只要其信任分數過低，系統仍會限制其對外傳播能力，以避免低可信度帳號因流量高而持續擴散假訊息。

二、研究目的

本專題的研究目的如下：

- (一) 建立一個以有向圖表示社群推播關係的模型。
- (二) 設計關係分數、互動分數與信任分數，形成可量化的推播分數。
- (三) 參考 X / Twitter Heavy Ranker 的加權排序概念，建立線性加權 Score 矩陣 [5][6]。
- (四) 透過信任限流門檻，限制高風險假訊息節點的對外傳播能力。
- (五) 透過推播門檻，移除推播價值不足的弱連結。

- (六) 使用 BFS 模擬訊息由起始節點逐層擴散的過程。
- (七) 使用 Dijkstra 演算法找出最容易傳播的高風險路徑。
- (八) 使用 PageRank 分析社群網路中的高影響力節點。
- (九) 使用強連通元件分析潛在回聲室結構。

三、 研究問題

本專題主要探討以下問題：

- (一) 如何將社群平台中的使用者推播關係轉換為有向圖模型？
- (二) 如何以關係、互動與信任三種使用者對使用者特徵建立推播分數？
- (三) 若某節點經常傳播假訊息，如何透過信任分數限制其對外傳播能力？
- (四) 哪些節點在有效推播圖中具有較高影響力？
- (五) 哪些路徑是假訊息最容易穿透的高風險傳播路徑？
- (六) 是否能透過強連通元件找出可能形成回聲室的群體？

四、 名詞解釋

(一) 圖 Graph

圖是由節點與邊所組成的數學結構，通常表示為：

$$G = (V, E)$$

其中， V 為節點集合， E 為邊集合。本專題將整個社群推播網路視為一張圖，使用者為節點，貼文可傳播的方向為邊。

(二) 節點 Vertex

節點是圖中的基本單位。本專題中，每一個節點代表一個社群平台使用者帳號。例如 A 、 B 、 C 、 D 可分別代表不同使用者。

(三) 邊 Edge

本專題中，一般圖模型的邊代表貼文或訊息可能沿著某個方向傳播。例如在擴散分析中， $A \rightarrow B$ 表示 A 的貼文可能被推播給 B 。惟在關係分數 RelationScore 的設計中， $A \rightarrow B$ 進一步解釋為 B 追蹤 A ，因此 B 較容易接收到 A 的內容。

(四) 有向圖 Directed Graph

若存在 $A \rightarrow B$ ，在一般擴散圖中代表 A 的貼文可傳播給 B ；而在本專題的關係分數設計中，則表示 B 有追蹤 A ，因此 B 較容易看到或接收 A 的內容，但不一定代表 A 也追蹤 B 。

(五) 有向邊 Directed Edge

有向邊是有方向的邊，可表示為：

$$(u, v) \in E$$

其中， u 為發文者或資訊來源， v 為接收者。在一般擴散分析中，有向邊代表節點 u 的貼文可推播給節點 v 。在關係分數 RelationScore 中， $u \rightarrow v$ 則表示 v 追蹤 u ，因此 v 較容易接收到 u

的內容。

(六) 加權圖 Weighted Graph

加權圖是指每條邊都具有權重的圖。本專題中的邊權重不是單純的 0 或 1，而是由關係分數、互動分數與信任分數共同計算出的推播分數 $S(u,v)$ 。分數越高，代表該方向的推播可能性越高。

(七) 權重 Weight

權重是邊上的數值，用來表示兩節點之間的連結強度。本專題中，權重可代表關係強度、互動程度、信任程度或最終推播分數。

(八) 鄰接矩陣 Adjacency Matrix

鄰接矩陣是用矩陣表示圖中節點連接關係的方法。若節點 u 可連到節點 v ，矩陣中對應位置會有數值。本專題中的關係矩陣 R 、互動矩陣 I 、信任矩陣 T 與推播分數矩陣 S ，皆可視為圖的矩陣表示方式。

(九) 入度 In-degree

入度表示有多少條邊指向某節點。若某節點入度高，代表許多其他節點的貼文可能傳播至該節點，因此該節點具有較高的資訊接收程度。

(十) 出度 Out-degree

出度表示某節點有多少條邊指向其他節點。若某節點出度高，代表它可以將訊息傳給較多節點，因此具有較高的對外擴散能力。

(十一) 路徑 Path

路徑是指從一個節點出發，沿著邊依序到達另一個節點的節點序列。例如：

$$A \rightarrow B \rightarrow C$$

代表訊息可能先由 A 傳給 B ，再由 B 傳給 C 。本專題使用路徑分析假訊息可能的傳播方向。

(十二) 可達性 Reachability

可達性表示在圖中是否能從某一節點沿著邊到達另一節點。若節點 v 可由節點 u 經由一條或多條有向邊到達，則表示 v 對 u 是可達的。本專題用可達性分析假訊息可能影響的範圍。

(十三) 連通性 Connectivity

連通性用於描述圖中節點彼此是否能透過邊連接。對社群網路而言，連通性越高，代表訊息越容易在不同節點之間傳播。

(十四) 強連通元件 Strongly Connected Component, SCC

在有向圖中，若一群節點彼此之間皆能透過有向路徑互相到達，則形成強連通元件。本專題使用 SCC 分析潛在回聲室，因為強連通群體中的訊息可能在群體內反覆流動。

(十五) 子圖 Subgraph

子圖是由原始圖中的部分節點與部分邊所組成的圖。本專題中的有

效推播圖 G' 可視為原始圖 G 經由信任門檻與推播門檻過濾後形成的子圖。

(十六) 圖修剪 Graph Pruning

圖修剪是指移除圖中不符合條件的節點或邊，使圖結構更清楚。本專題透過信任門檻移除高風險節點的對外邊，並透過推播門檻移除低分弱邊。

(十七) 廣度優先搜尋 Breadth-First Search, BFS

BFS 是一種從起始節點開始，逐層拜訪鄰近節點的圖搜尋演算法。本專題使用 BFS 模擬假訊息由起始節點一層一層向外擴散的過程。

(十八) Dijkstra 演算法

Dijkstra 演算法用於尋找圖中兩個節點之間的最低成本路徑。本專題將推播分數轉換為傳播成本，使 Dijkstra 可用於分析假訊息最容易穿透的高風險路徑。

(十九) PageRank

PageRank 是一種衡量節點在網路中重要性的演算法。本專題使用 PageRank 分析有效推播圖中的高影響力節點。若某節點被多個高分節點指向，或位於重要傳播位置，其 PageRank 分數通常較高。

(二十) 回聲室 Echo Chamber

回聲室是指一群使用者因高度互動、相似立場或高信任關係而形成封閉群體，使相同資訊在群體內反覆傳播。本專題使用 SCC、平均互動分數與平均信任分數判斷潛在回聲室。

(二十一) 信任限流 Trust Gating

信任限流是本專題的核心機制。當某節點的平均信任分數低於門檻時，系統會將該節點的對外推播分數設為 0，使該節點仍存在於圖中，但無法繼續將訊息推播出去。

第二章、文獻探討

一、社群推薦系統與互動權重

現代社群推薦系統通常會同時考量使用者關係、貼文內容特徵、使用者興趣、互動歷史與負面回饋等因素。X / Twitter 公開的推薦演算法 repository 說明，其推薦系統是一組服務與工作，用於在 For You Timeline、Search、Explore、Notifications 等產品表面提供貼文與內容推薦 [5]。

本專題參考 X / Twitter Heavy Ranker 的公開分數設計。Heavy Ranker README 說明，該模型用於對通過候選擷取階段的 For You timeline tweets 進行排序，並會輸出多種互動機率；其排序分數採用加權總和形式，即 $score = \sum_i (weight_i \times probability_i)$ [6]。

Heavy Ranker 的公開權重顯示，不同互動行為並非同等重要。例如 Favorite / Like 屬於較低正向權重，而 Reply、Good click、Good profile click 等較深層互動具有較高權重；Negative feedback 與 Report 則具有大幅負權重 [6]。此概念顯示，推薦系統不應只判斷「是否有互動」，也應判斷互動深度與訊號方向。因此，本專題將互動分數設計為 0.00 至 1.00 的連續值，並將假訊息通報反映於信任扣分與限流機制 [6]。

二、 假訊息傳播與圖論分析

假訊息在社群媒體中的擴散不只與貼文內容本身有關，也與使用者網路結構、互動關係與擴散路徑有關。Shu 等人指出，社群媒體假訊息偵測可從資料探勘角度分析，且使用者互動與社群網路結構對假訊息傳播具有重要意義 [2]。

圖論適合描述社群傳播問題，因為使用者可表示為節點，資訊流向可表示為有向邊，而邊權重可用於表示傳播強度。本專題採用有向圖：

$$G = (V, E)$$

其中， V 為使用者節點集合， E 為有向邊集合。若存在：

$$(u, v) \in E$$

代表節點 u 的貼文具有傳播至節點 v 的可能性。

需要注意的是，在後續 RelationScore 的關係分數設計中， $(u, v) \in E$ 進一步被解釋為節點 v 追蹤節點 u ，因此 v 較容易接收或被推播 u 的內容。

三、 影響力擴散與關鍵節點

Domingos 與 Richardson 提出網路中的某些節點具有較高網路價值，因為其行為可能影響其他節點，進而形成影響力擴散 [3]。在社群推播情境中，若某節點能透過多條高權重路徑影響其他節點，則該節點具有較高推播影響力。

因此，本專題使用 PageRank 分析有效推播圖中的節點影響力。PageRank 不僅考慮節點連結數，也考慮指向該節點的來源是否具有重要性，適合用於分析社群網路中的關鍵節點 [1]。

四、 信任模型與假訊息限流

Sherchan 等人整理社群網路中的信任研究，指出信任可作為社群網路中的重要關係特徵，且使用者互動會影響信任程度 [4]。本專題依此將信任納入推播模型中，並將信任分數設計為具有「限流」與「阻斷傳播」功能的變數。

若某節點雖然具有高互動，但經常傳播假訊息，則不應因互動高而持續被推薦。因此，本專題不只將 TrustScore 作為 Score 公式中的一項，也額外設計 TrustGateThreshold。當節點信任分數低於門檻時，系統會將該

節點對外推播分數歸零，使其無法繼續擴散訊息。

第三章、研究方法


一、系統整體架構

本專題以 Python 實作互動式 GUI 系統。系統使用 NetworkX 建立與分析圖結構，使用 NumPy 處理矩陣運算，使用 PySide6 製作桌面介面，並使用 Matplotlib 繪製圖形。

表 3-1 系統使用技術

技術	用途
Python	主要程式語言
NetworkX	建立有向圖、BFS、Dijkstra、PageRank、SCC
NumPy	矩陣運算與分數計算
PySide6	GUI 桌面介面
Matplotlib	視覺化繪製圖形

系統主要流程如下：



二、圖模型定義

本專題將社群推播網路表示為有向圖：

$$G = (V, E) \quad (3-1)$$

其中， V 為節點集合，代表使用者； E 為有向邊集合，代表貼文可能傳播的方向。

若存在有向邊：

$$u \rightarrow v \quad (3-2)$$

在本專題的整體擴散分析中， $u \rightarrow v$ 表示訊息可由 u 流向 v ；而在 RelationScore 的關係分數設定中，此方向對應為 v 追蹤 u ，因此 v 較容易接收到 u 的貼文。

三、關係分數 RelationScore

關係分數用於表示兩節點之間是否存在追蹤關係，並衡量接收者是否較容易看到或被推播發文者的內容。在本專題的 RelationScore 設計中，若存在有向邊 $u \rightarrow v$ ，其語意為 v 有追蹤 u 。因此， u 發布內容時， v 較容易接收到或被推播 u 的貼文。

表 3-2 關係分數設定

關係狀態	圖論表示	說明	RelationScore
無關係	無 $u \rightarrow v$	未追蹤 u ，因此 v 較不容易接收到 u 的內容。	0.0
單向關係	$u \rightarrow v$	追蹤 u ，因此 v 較容易看到或被推播 u 的內容。	0.7
雙向關係	$u \rightarrow v$ 且 $v \rightarrow u$	與 v 互相追蹤，代表雙方關係更強，內容更容易被看見與互動。	1.0

關係分數 $R(u, v)$ 如下：

$$R(u, v) = \begin{cases} 0.0, & (u, v) \notin E \\ 0.7, & (u, v) \in E \text{ 且 } (v, u) \notin E \\ 1.0, & (u, v) \in E \text{ 且 } (v, u) \in E \end{cases} \quad (3-3)$$

設定 0.7 作為單向關係分數，是因為單向追蹤代表內容具有基本傳播路徑，但不一定表示雙方有密切互動，因此不給予滿分。雙向關係則代表兩者之間具有更強社群連結，因此設定為 1.0。無關係時不存在直接傳播路徑，因此分數為 0.0。

四、互動分數 InteractionScore

互動分數表示接收者對發文者內容的興趣程度。若節點 v 經常對節點 u 的內容按讚、留言、分享、點擊或查看作者頁，則 $I(u, v)$ 較高。

互動分數範圍為：

$$0 \leq I(u, v) \leq 1 \quad (3-4)$$

表 3-3 互動分數區間設定

互動程度	分數範圍	可能行為	設計意義
無互動	0.00~0.20	幾乎沒有觀看、按讚或點擊	不應高度推薦
低互動	0.21~0.40	偶爾觀看或按讚	有少量接觸，但推薦強度低
中互動	0.41~0.70	經常按讚，偶爾留言或點擊	具有一定推薦價值
高互動	0.71~1.00	經常留言、分享、點擊、查看作者	代表高度興趣，推薦價值高

互動分數採連續區間，是為了避免分類空白。例如 0.35 可歸為低互動，0.58 可歸為中互動，0.76 可歸為高互動。此設計較適合矩陣運算，也能使排序結果更細緻。

本專題參考 Heavy Ranker 對互動深度的權重設計。Heavy Ranker 中 Favorite / Like 權重較低，而 Reply、Good click、Good profile click 等深層互動權重較高，表示深層互動比單純按讚更能代表使用者興趣 [6]。

表 3-4 Heavy Ranker 互動權重概念與本專題對應

Heavy Ranker 互動行為	權重概念	本專題對應
Favorite / Like	低正向權重	低互動或中互動
Retweet	一般正向權重	中互動
Reply	高正向權重	高互動
Good click	高正向權重	高互動
Good profile click	高正向權重	高互動
Reply engaged by author	極高正向權重	高互動與雙向關係
Negative feedback	大幅負向權重	降低推播或降低信任
Report	極大負向權重	通報假訊息並扣除信任

五、信任分數 TrustScore

信任分數表示節點本身的可信程度。本專題使用信任矩陣 T 表示節點 u 對外傳播至節點 v 時的信任值：

$$T[u][v] = T(u, v) \quad (3-5)$$

由於程式中保留的是信任矩陣，因此某節點 u 的整體信任分數以其對外

信任列的平均值表示：

$$NodeTrust(u) = \frac{1}{|V| - 1} \sum_{\substack{v \in V \\ v \neq u}} T(u, v) \quad (3-6)$$

信任分數範圍如下：

$$0 \leq T(u, v) \leq 1 \quad (3-7)$$

表 3-5 信任分數區間設定

TrustScore 區間	節點狀態	說明	傳播效果
0.80~1.00	高信任	長期傳播可信資訊，假訊息紀錄少	正常傳播
0.50~0.79	普通信任	多數內容正常，但可能有低品質內容	輕度保留
0.20~0.49	低信任	曾多次傳播假訊息	明顯降低曝光
0.00~0.19	高風險	經常傳播假訊息	阻斷對外傳播

表 3-6 信任更新機制

節點行為	程式更新方式	設計原因
通報優良互動	+0.05	正確或良好訊息可提升可信度，但避免短時間快速洗白
通報假訊息	-0.20	假訊息危害較大，因此扣分幅度高於加分幅度
分數上限	1.00	避免超出分數範圍
分數下限	0.00	避免出現負分

當節點 u 被通報優良互動時，其對外信任值更新為：

$$T_{\text{new}}(u, v) = \min(1.0, T_{\text{old}}(u, v) + 0.05) \quad (3-8)$$

當節點 u 被通報散播假訊息時，其對外信任值更新為：

$$T_{\text{new}}(u, v) = \max(0.0, T_{\text{old}}(u, v) - 0.20) \quad (3-9)$$

此設計採「扣分大於加分」原則，因為假訊息造成的外部成本通常高於一般正確訊息的正面效益。若加分與扣分相同，節點可能透過少量正常內容快速抵銷多次假訊息紀錄，不利於假訊息限流。Heavy Ranker 中 Report 與 Negative feedback 具有大幅負權重，也反映負面訊號在排序中應被高度重視 [6]。

六、最終推播分數矩陣 Score Matrix

本專題參考 Heavy Ranker 的線性加權概念，將關係矩陣 R 、互動矩陣 I 與信任矩陣 T 整合為 Score 矩陣 S ：

$$S(u, v) = \alpha R(u, v) + \beta I(u, v) + \gamma T(u, v) \quad (3-10)$$

其中：

$$\alpha + \beta + \gamma = 1 \quad (3-11)$$

程式預設為：

$$\alpha = 0.30, \beta = 0.40, \gamma = 0.30 \quad (3-12)$$

因此，最終推播分數可寫為：

$$S(u, v) = 0.30R(u, v) + 0.40I(u, v) + 0.30T(u, v) \quad (3-13)$$

表 3-7 Score 權重設定

項目	權重	原因
RelationScore	0.30	表示接收者是否追蹤發文者。追蹤關係可提高內容被看見或被推播的可能性，但追蹤不代表一定有高度興趣，因此不設為最高
InteractionScore	0.40	最能反映接收者對發文者內容的實際興趣，因此權重最高
TrustScore	0.30	表示可信度與傳播風險，並由信任限流門檻額外強化

此設計的核心是平衡「可傳播、感興趣、可信任」三個條件。若只看關係，模型會過度依賴追蹤關係，無法反映接收者是否真的對發文者內容感興趣；若只看互動，爭議內容可能因留言與點擊較多而被放大；若只看信任，則可能忽略接收者實際興趣。因此，本專題採用三者加權總和，並額外加入門檻機制處理高風險節點與低價值邊。

七、信任限流門檻 TrustGateThreshold

程式預設信任限流門檻為：

$$TrustGateThreshold = 0.20 \quad (3-14)$$

若節點 u 的平均對外信任分數低於 0.20：

$$NodeTrust(u) < 0.20 \quad (3-15)$$

則系統會將該節點所有對外 Score 設為 0：

$$S(u, v) = 0, \forall v \in V \quad (3-16)$$

圖論表示如下：

$$E_1 = E - \{(u, v) \mid NodeTrust(u) < 0.20\} \quad (3-17)$$

表 3-8 TrustGateThreshold 設定原因

門檻值	對應區間	設計原因
0.20	高風險與低信任分界	0.00~0.19 被定義為高風險節點，代表經常傳播假訊息，因此應阻斷對外傳播
不設為 0.50	避免過度刪邊	若 0.50 以下全部阻斷，低信任但仍可觀察的節點會被過早移除
不設為 0.10	避免阻斷太晚	若門檻太低，高風險節點仍可能保留傳播能力

此設計代表高風險節點仍存在於圖中，但失去對外傳播能力。換言之，該節點仍可接收訊息，但其自身貼文無法再被推播出去。

八、推播門檻 PushThreshold

程式預設推播門檻為：

$$PushThreshold = 0.40 \quad (3-18)$$

若某條有向邊的推播分數低於 0.40：

$$S(u, v) < 0.40 \quad (3-19)$$

則該邊不會被視為有效推播邊。圖論表示如下：

$$E_2 = E_1 - \{(u, v) \mid S(u, v) < 0.40\} \quad (3-20)$$

最後形成有效推播圖：

$$G' = (V, E_2) \quad (3-21)$$

表 3-9 PushThreshold 設定原因

門檻值	設計意義	原因
0.40	移除弱推播邊	低於 0.40 通常代表關係、互動或信任至少有一項明顯不足
不設為 0.20	避免保留過多弱邊	門檻太低會讓低互動、低信任邊仍可傳播
不設為 0.60	避免圖過度稀疏	門檻太高會刪除大量中等推播價值的正常邊
0.40 的折衷性	保留中等以上推播強度	可在移除弱連結與保留正常傳播之間取得平衡

推播門檻可視為加權圖修剪。若所有低權重邊都被保留，圖可能過度密集，導致分析結果不清楚；若門檻過高，圖則可能過度破碎。因此，0.40 被設定為弱推播與中等推播的分界，用於移除低價值傳播路徑。

九、有效推播圖建構

原始圖為：

$$G = (V, E) \quad (3-22)$$

第一層過濾為信任限流：

$$E_1 = E - \{(u, v) \mid \text{NodeTrust}(u) < \text{TrustGateThreshold}\} \quad (3-23)$$

第二層過濾為推播門檻：

$$E_2 = E_1 - \{(u, v) \mid S(u, v) < \text{PushThreshold}\} \quad (3-24)$$

最後得到有效推播圖：

$$G' = (V, E_2) \quad (3-25)$$

十、 BFS 假訊息擴散模擬

BFS 用於模擬訊息從起始節點逐層向外擴散的過程。當某條邊的 Score 達到推播門檻時，訊息才可沿該邊傳播。

$$v \text{ 可被 } u \text{ 感染} \Leftrightarrow S(u, v) \geq \text{PushThreshold} \quad (3-26)$$

也就是：

$$S(u, v) \geq 0.40 \quad (3-27)$$

BFS 演算法如下：

演算法 1：BFS 假訊息擴散模擬

Input：起始節點 s 、節點集合 V 、推播分數矩陣 S 、推播門檻 θ

Output：感染節點集合 Infected 、傳播順序 Order

1. $\text{Infected} \leftarrow \{s\}$
 2. $\text{Queue} \leftarrow [s]$
 3. $\text{Order} \leftarrow [s]$
 4. while Queue is not empty do
 5. $u \leftarrow \text{Queue.pop}(0)$
 6. for each $v \in V$ do
 7. if $v \notin \text{Infected}$ and $S(u, v) \geq \theta$ then
 8. $\text{Infected} \leftarrow \text{Infected} \cup \{v\}$
 9. $\text{Queue.push}(v)$
 10. $\text{Order.push}(v)$
 11. end if
 12. end for
 13. end while
 14. return $\text{Infected}, \text{Order}$
-

十一、 Dijkstra 高風險傳播路徑

Dijkstra 原本用於尋找最低成本路徑。本專題將高 Score 視為高傳播可能性，因此將 Score 轉換為 Cost：

$$\text{Cost}(u, v) = \frac{1}{S(u, v) + \varepsilon} \quad (3-28)$$

其中：

$$\varepsilon = 0.0001 \quad (3-29)$$

當 $S(u,v)$ 越高， $Cost(u,v)$ 越低。Dijkstra 找到的最低成本路徑，即為假訊息最容易穿透的高風險傳播路徑：

$$HighRiskPath(s,t) = \arg \min_{P:s \rightarrow t} \sum_{(u,v) \in P} Cost(u,v) \quad (3-30)$$

其中， P 表示從起點 s 到終點 t 的一條路徑。

十二、PageRank 影響力分析

PageRank 用於衡量節點在整體有效推播圖中的影響力。系統使用 $S(u,v)$ 作為加權邊：

$$PR(v) = \frac{1-d}{|V|} + d \sum_{u \in In(v)} \frac{PR(u) \cdot S(u,v)}{\sum_{k \in Out(u)} S(u,k)} \quad (3-31)$$

其中， d 為阻尼係數，常見設定為：

$$d = 0.85 \quad (3-32)$$

節點 PageRank 越高，代表該節點越可能位於重要傳播位置，或被多個高權重節點指向。

十三、SCC 回聲室分析

強連通元件用於找出有向圖中彼此可以互相到達的節點群體。若一群節點形成 SCC，表示資訊可能在該群體中循環傳播。

本專題設定：若某一強連通元件 C 的節點數符合：

$$|C| \geq 3 \quad (3-33)$$

則視為潛在回聲室。

若該群體同時滿足：

$$AvgInteraction(C) \geq 0.70 \quad (3-34)$$

且：

$$AvgTrust(C) \geq 0.60 \quad (3-35)$$

則進一步視為高風險回聲室。

平均互動分數定義為：

$$AvgInteraction(C) = \frac{1}{|E_C|} \sum_{(u,v) \in E_C} I(u,v) \quad (3-36)$$

平均信任分數定義為：

$$AvgTrust(C) = \frac{1}{|E_C|} \sum_{(u,v) \in E_C} T(u,v) \quad (3-37)$$

其中， E_C 表示強連通元件 C 內部的有向邊集合。

表 3-10 SCC 回聲室判斷條件

條件	門檻	原因
節點數	≥ 3	至少三個節點較能形成群體傳播結構
平均互動分數	≥ 0.70	高互動代表群體內資訊流動頻繁
平均信任分數	≥ 0.60	成員間信任偏高，訊息較容易被接受
同時滿足三者	高風險回聲室	假訊息進入後可能在群體內重複擴散

第四章、結果與討論

一、系統完成結果

本專題完成一套互動式 GUI 系統。系統可新增節點、刪除節點、新增有向邊、刪除有向邊，並即時計算關係矩陣、互動矩陣、信任矩陣與 Score 矩陣。使用者可通報節點散播假訊息，使該節點信任分數下降；也可通報節點有優良互動，使其信任分數上升。

系統主要分頁包含：

- (一) 關係圖
- (二) 互動矩陣
- (三) 信任圖
- (四) Score 分析
- (五) 圖形分析
- (六) 推播順序




圖 4-1 系統 GUI 主畫面

二、 預設資料與圖結構

系統內建預設節點：

$$V = \{A, B, C, D, E\}$$

預設有向邊包含：

$A \rightarrow B, A \rightarrow C, B \rightarrow C, C \rightarrow B, B \rightarrow D, C \rightarrow D, C \rightarrow E, D \rightarrow E, E \rightarrow D, E \rightarrow B$

此圖中包含單向追蹤與雙向追蹤關係。在 RelationScore 的語意中， $A \rightarrow B$ 表示 B 追蹤 A，因此 B 較容易接收到 A 的貼文。若同時存在 $B \rightarrow C$ 與 $C \rightarrow B$ ，則表示 B 與 C 互相追蹤，形成雙向追蹤關係，因此其 RelationScore 為 1.0；而 $A \rightarrow B$ 若不存在 $B \rightarrow A$ ，則屬於單向追蹤，RelationScore 為 0.7。

三、 信任限流結果

當某節點被多次通報假訊息後，其 TrustScore 會下降。若其 NodeTrust 低於 0.20，系統會將該節點所有對外 Score 設為 0。此時該節點仍存在於圖中，但已無法將訊息推播給其他節點。

此結果符合本專題的核心設計：高風險節點不必從圖中刪除，因為刪除節點會使圖結構資訊消失；較合理的方式是保留節點，但移除其對外傳播能力。如此能模擬社群平台中「限流」或「降權」的概念。

四、 推播門檻結果

會移除 Score 低於 0.40 的弱推播邊。若接收者雖然追蹤發文者，但互動分數低或發文者信任分數低，則最終 Score 仍可能無法達到推播門檻。此時該邊不會被納入有效推播圖。

此設計能避免只要有關係就推播的問題，也能避免假訊息透過低價值弱連結繼續擴散。從圖論角度來看，推播門檻使原始圖 G 轉換為較乾淨的有效推播圖 G'。

五、 BFS 擴散結果

BFS 模擬可顯示訊息由起始節點逐層向外傳播的過程。當一條邊的 Score 達到 PushThreshold 時，訊息才可沿該邊傳播。若某高風險節點被信任限流，則其對外 Score 為 0，因此 BFS 擴散會在該節點停止。

此結果顯示，加入信任門檻後，假訊息不會單純因圖中存在邊就持續擴散，而會受到節點可信度與邊推播強度限制。

六、 Dijkstra 高風險路徑結果

系統將 Score 轉換為 Cost，並以 Dijkstra 找出最低成本路徑。由於 Cost 與 Score 成反比，因此 Dijkstra 找出的路徑可視為假訊息最容易穿透的高風險傳播路徑。

當某中繼節點因假訊息通報而信任下降時，該節點對外 Score 會下降，路徑成本會上升。若其信任低於 0.20，則對外路徑會被阻斷。

七、 PageRank 影響力結果

PageRank 分析可找出有效推播圖中的高影響力節點。若某節點被多個高 Score 邊指向，或位於重要傳播位置，則其 PageRank 較高。

但若某節點信任分數過低，即使其原本連結多，系統也會因信任限流將其對外 Score 設為 0。此時該節點的傳播影響力會被降低。這表示本專題的 PageRank 結果不只反映連結數，也受到信任機制影響。

八、 SCC 回聲室結果

SCC 分析可找出有向圖中彼此可互相到達的節點群體。若一個 SCC 節點數大於或等於 3，且群體內平均互動分數與平均信任分數皆高，則可視為高風險回聲室。

此結果代表假訊息若進入高度互動且高信任的封閉群體，可能在群體內反覆循環傳播。因此，SCC 分析可作為觀察回聲室結構的工具。

九、 綜合討論

本專題的重點不在於完整模擬大型社群平台的 AI 推薦系統，而是將其核心概念簡化為圖論模型。實際社群平台可能會分析內容語意、使用者興趣、停留時間、點擊率、互動機率與多種 AI 預測分數；本專題則聚焦於使用者對使用者的追蹤關係、互動程度與信任狀態，並以線性加權方式建立推播分數。

此設計具有兩個優點。第一，模型清楚且可解釋，所有推播分數皆可由矩陣與公式計算。第二，信任分數能避免高互動但低可信節點持續擴散訊息。若只依互動分數推播，假訊息可能因爭議性高而獲得大量曝光；但加入信任限流後，經常傳播假訊息的節點會逐漸喪失對外傳播能力。

因此，本專題能清楚展示「流量導向推播」與「信任導向限流」之間的差異，並以圖論演算法呈現其在傳播路徑、影響力與回聲室結構上的效果。

第五章、結論與建議

一、 研究結論

本專題完成一套以圖論為基礎的動態信任圖模型，本專題將社群平台中的使用者表示為節點，並以有向邊描述訊息可能流動的方向；在關係分數設計中，則將 $u \rightarrow v$ 解釋為 v 追蹤 u ，用以估計接收者較容易看到發文者內容的程度，最後再結合互動分數與信任分數計算最終推播分數。系統參考 X / Twitter Heavy Ranker 的加權排序概念，將多個使用者對使用者特徵整合為線性 Score 矩陣 [5][6]。

研究結果顯示，TrustGateThreshold=0.20 可阻斷高風險節點的對外傳播能力，而 PushThreshold=0.40 可移除低推播價值的弱邊。BFS 可用於模擬訊息擴散，Dijkstra 可找出高風險傳播路徑，PageRank 可分析高影響力節點，SCC 則可偵測潛在回聲室群體。

本專題成功將有向圖、加權圖、BFS、Dijkstra、PageRank 與 SCC 等圖論概念應用於假訊息傳播分析。系統雖為簡化模型，但能清楚展示加入信任機制後，假訊息節點會受到限流，進而降低其對外傳播能力。

二、 研究限制

- (一) 本系統目前使用模擬資料，尚未串接真實社群平台資料。
- (二) 互動分數由使用者手動輸入或隨機產生，尚未由真實按讚、留言、分享與點擊紀錄自動計算。
- (三) 信任更新規則採固定加減值，尚未依假訊息嚴重程度調整扣分幅度。
- (四) 系統以使用者對使用者關係為主，尚未分析貼文內容語意與個人化興趣模型。
- (五) 目前未進行大規模節點與邊的效能測試。

三、 未來建議

- (一) 加入 CSV 匯入功能，使系統可讀取真實或半真實社群網路資料。
- (二) 將互動分數改為由按讚、留言、分享、點擊與觀看時間自動計算。
- (三) 加入貼文內容分數，使模型能同時考慮「使用者對使用者」與「使用者對內容」的興趣。
- (四) 依假訊息嚴重程度設計不同 TrustScore 扣分。
- (五) 加入更多中心性指標，例如 Betweenness Centrality 與 Closeness Centrality。

第六章、參考文獻

- [1] 賴寶蓮，圖形理論（Graph Theory）課程投影片。
- [2] Shu, K., Sliva, A., Wang, S., Tang, J., & Liu, H. “Fake news detection on social media: A data mining perspective.” ACM SIGKDD Explorations Newsletter, 19(1), 22 – 36, 2017.
- [3] Domingos, P., & Richardson, M. “Mining the network value of customers.” Proceedings of the Seventh ACM SIGKDD International Conference on Knowledge Discovery and Data Mining, 57 – 66, 2001.
- [4] Sherchan, W., Nepal, S., & Paris, C. “A survey of trust in social networks.” ACM Computing Surveys, 45(4), 1 – 33, 2013.
- [5] X / Twitter. twitter/the-algorithm. GitHub repository.
- [6] X / Twitter. twitter/the-algorithm-ml, projects/home/recap, Heavy Ranker README.

附錄

本專題在主題發想、系統設計、系統架構整理、參數設計說明與報告文字撰寫過程中使用生成式 AI 作為輔助工具。AI 協助內容包含：整理動態信任圖模型的研究動機、協助將關係分數、互動分數與信任分數轉換為表格與公式、協助將 BFS、Dijkstra、PageRank 與 SCC 對應至假訊息傳播分析情境，以及協助檢查報告章節是否符合期末專題書面報告格式。最終模型、程式實作與報告內容由作者依實際專題成果修正後完成。



圖 7-1 AI 協助專題發想




圖 7-2 AI 協助專題程式



圖 7-3 AI 協助專題報告